

Anализar POMs de Maven

Para abordar su consulta, proporcionaré una solución para generar un grafo de dependencias en formato DOT al encontrar recursivamente todos los archivos pom.xml en un directorio y analizar sus dependencias, sin suponer una estructura de proyecto Maven multimodular fija como la del ejemplo (project/module1/pom.xml, etc.). El script se centrará en recolectar primero todos los archivos pom.xml, luego en analizarlos para determinar las dependencias entre módulos y generar el grafo.

Descripción General de la Solución

Aquí está lo que hará el script:

- 1. Recolección Recursiva de Archivos pom.xml:** Recorrerá el directorio raíz especificado para encontrar todos los archivos pom.xml, independientemente de su ubicación o estructura.
- 2. Análisis de Información del Módulo:** Extraerá groupId, artifactId y dependencias de cada pom.xml.
- 3. Manejo de Herencia de groupId:** Si un pom.xml no especifica un groupId, lo heredará de una declaración <parent>, si está presente.
- 4. Identificación de Dependencias Intra-Proyecto:** Asociará dependencias a módulos dentro del proyecto en función de groupId y artifactId.
- 5. Generación de Salida en Formato DOT:** Creará un grafo dirigido de dependencias entre módulos.

Este enfoque no depende de una jerarquía de directorios predefinida ni asume que los archivos pom.xml padres estén en directorios padres.

Script en Python

A continuación se muestra el script en Python adaptado a sus requisitos:

```
import os
import sys
import xml.etree.ElementTree as ET

# Definir el espacio de nombres de Maven POM
NS = "{http://maven.apache.org/POM/4.0.0}"

# Caché para groupId para evitar análisis redundantes
group_id_cache = {}

def get_group_id(pom_path, pom_map):
    """
    """
```

Extraer el groupId de un archivo pom.xml, considerando la herencia del padre.

Args:

```
pom_path (str): Ruta al archivo pom.xml.  
pom_map (dict): Mapeo de rutas de archivos pom.xml a sus datos analizados.
```

Returns:

```
str: El groupId del módulo.
```

```
"""
```

```
if pom_path in group_id_cache:  
    return group_id_cache[pom_path]  
  
tree = ET.parse(pom_path)  
root = tree.getroot()  
group_id_elem = root.find(NS + 'groupId')  
  
if group_id_elem is not None:  
    group_id = group_id_elem.text.strip()  
else:  
    # Verificar la declaración del parent  
    parent = root.find(NS + 'parent')  
    if parent is not None:  
        parent_group_id = parent.find(NS + 'groupId').text.strip()  
        parent_artifact_id = parent.find(NS + 'artifactId').text.strip()  
        parent_relative_path = parent.find(NS + 'relativePath')  
        if parent_relative_path is not None and parent_relative_path.text:  
            parent_pom_path = os.path.normpath(  
                os.path.join(os.path.dirname(pom_path), parent_relative_path.text)  
            )  
        else:  
            # Predeterminar al directorio parent si relativePath está omitido  
            parent_pom_path = os.path.join(os.path.dirname(pom_path), '..', 'pom.xml')  
            parent_pom_path = os.path.normpath(parent_pom_path)  
  
        if parent_pom_path in pom_map:  
            group_id = get_group_id(parent_pom_path, pom_map)  
        else:  
            raise ValueError(f"POM parent no encontrado para {pom_path}: {parent_pom_path}")  
    else:  
        raise ValueError(f"No groupId o parent especificado en {pom_path}")
```

```

group_id_cache[pom_path] = group_id
return group_id

def get_artifact_id(pom_path):
    """
    Extraer el artifactId de un archivo pom.xml.

    Args:
        pom_path (str): Ruta al archivo pom.xml.

    Returns:
        str: El artifactId del módulo.

    """
    tree = ET.parse(pom_path)
    root = tree.getroot()
    artifact_id_elem = root.find(NS + 'artifactId')

    if artifact_id_elem is None:
        raise ValueError(f"pom.xml debe especificar artifactId: {pom_path}")

    return artifact_id_elem.text.strip()

def get_dependencies(pom_path):
    """
    Extraer la lista de dependencias de un archivo pom.xml.

    Args:
        pom_path (str): Ruta al archivo pom.xml.

    Returns:
        list: Lista de tuplas (groupId, artifactId) para cada dependencia.

    """
    tree = ET.parse(pom_path)
    root = tree.getroot()
    dependencies = []

    for dep in root.findall(NS + 'dependencies/' + NS + 'dependency'):
        dep_group_id_elem = dep.find(NS + 'groupId')
        dep_artifact_id_elem = dep.find(NS + 'artifactId')

```

```

    if dep_group_id_elem is not None and dep_artifact_id_elem is not None:
        dep_group_id = dep_group_id_elem.text.strip()
        dep_artifact_id = dep_artifact_id_elem.text.strip()
        dependencies.append((dep_group_id, dep_artifact_id))

    return dependencies

if __name__ == '__main__':
    # Verificar argumentos de la línea de comandos
    if len(sys.argv) != 2:
        print("Uso: python script.py <directorio_raiz>")
        sys.exit(1)

    root_dir = sys.argv[1]
    if not os.path.isdir(root_dir):
        print(f"Error: {root_dir} no es un directorio")
        sys.exit(1)

    # Paso 1: Encontrar recursivamente todos los archivos pom.xml
    pom_files = [
        os.path.join(root, file)
        for root, _, files in os.walk(root_dir)
        for file in files if file == 'pom.xml'
    ]

    if not pom_files:
        print(f"No se encontraron archivos pom.xml en {root_dir}")
        sys.exit(1)

    # Paso 2: Construir un diccionario de todos los POMs para búsquedas de padres
    pom_map = {pom_file: None for pom_file in pom_files}

    # Paso 3: Extraer información del módulo
    modules = {} # (groupId, artifactId) -> pom_path
    for pom_file in pom_files:
        try:
            group_id = get_group_id(pom_file, pom_map)
            artifact_id = get_artifact_id(pom_file)
            modules[(group_id, artifact_id)] = pom_file
        except ValueError as e:

```

```

print(f"Advertencia: Saltando {pom_file} debido a error: {e}")
continue

# Paso 4: Analizar dependencias
dependencies = set()
for pom_file in pom_files:
    try:
        importer_group_id = get_group_id(pom_file, pom_map)
        importer_artifact_id = get_artifact_id(pom_file)
        importer_key = (importer_group_id, importer_artifact_id)
        deps = get_dependencies(pom_file)
        for dep_group_id, dep_artifact_id in deps:
            dep_key = (dep_group_id, dep_artifact_id)
            if dep_key in modules and dep_key != importer_key:
                # Agregar dependencia como tupla (importador, importado) usando artifactId para simplicidad
                dependencies.add((importer_artifact_id, dep_artifact_id))
    except ValueError as e:
        print(f"Advertencia: Error al procesar dependencias en {pom_file}: {e}")
        continue

# Paso 5: Salida en formato DOT
print('digraph G {')
for from_module, to_module in sorted(dependencies):
    print(f'    "{from_module}" -> "{to_module}";')
print('}')

```

Cómo Funciona

1. Entrada de Línea de Comandos

- Toma un solo argumento: <directorio_raiz>, el punto de partida para la búsqueda recursiva.
- Valida que sea un directorio.

2. Encontrar Archivos pom.xml

- Usa os.walk para recorrer recursivamente el árbol de directorios y recolectar todos los archivos pom.xml en una lista.

3. Análisis de Información del Módulo

- **Group ID (groupId):**
 - Extraído de cada pom.xml.
 - Si no está presente, busca una sección <parent> y resuelve el groupId del POM padre referenciado usando relativePath (o predetermina al directorio padre si está omitido).
 - Cachéa resultados para evitar reanálisis.
- **Artifact ID (artifactId):** Debe estar presente en cada pom.xml.
- **Dependencias:** Extrae pares (groupId, artifactId) de la sección <dependencies>.

4. Análisis de Dependencias

- Construye un mapa de (groupId, artifactId) a pom_path para todos los módulos.
- Para cada pom.xml, verifica sus dependencias contra el mapa de módulos para encontrar dependencias intra-proyecto.
- Excluye dependencias de sí mismo (donde un módulo depende de sí mismo).
- Registra dependencias como pares (importer_artifactId, imported_artifactId).

5. Salida en Formato DOT

- Genera un grafo dirigido en formato DOT, usando artifactId como etiquetas de nodos para simplicidad.
-

Ejemplo de Uso

Supongamos que su estructura de directorios es irregular:

```
myproject/
  app/pom.xml (groupId="com.myapp", artifactId="app", depende de "core")
  libs/core/pom.xml (groupId="com.myapp", artifactId="core")
  tools/util/pom.xml (groupId="com.myapp", artifactId="util", depende de "core")
```

Ejecute el script:

```
python script.py myproject
```

Salida:

```
digraph G {
    "app" -> "core";
    "util" -> "core";
}
```

Esto muestra que tanto `app` como `util` dependen de `core`.

Notas y Limitaciones

- **Sin Agrupación por Directorio:** A diferencia del script original en el rastro de pensamiento, esta versión no agrupa módulos por estructura de directorios ya que no lo solicitó. Usa `artifactId` directamente en el grafo.
- **Resolución de Padre:** Depende de `relativePath` en la sección `<parent>` o asume que el POM padre está en el directorio padre si está omitido. Si el POM padre no está en el conjunto recolectado, lanza un error.
- **Coincidencia Simple:** Coincide dependencias solo por `groupId` y `artifactId`, ignorando versiones.
- **Sin Sustitución de Propiedades:** No maneja propiedades de Maven como `${project.groupId}`.
- **Manejo de Errores:** Salta archivos `pom.xml` problemáticos con una advertencia en lugar de fallar por completo.

Este script cumple con su requisito de “iterar recursivamente, obtener todos los POMs primero y luego analizar” sin suponer una estructura de archivos fija. ¡Hágamelo saber si necesita ajustes!